



Pràctica 8.2: Web Scraping (XPath)

Lliuraments

Els resultats d'aquesta part de la pràctica s'hauran d'entregar en format PDF i l'entrega pot ser a través de GIT* o el moodle.

* S'ha d'entregar l'enllaç del GIT al moodle.

Guió

Amb l'ajuda de l'inspector d'elements del navegador, investiga com està formatada la pàgina <https://scrapepark.org/> . Aquesta pàgina està preparada per fer *web scraping*, de manera que les rutes per arribar als diferents elements no són trivials.

Exercici 1

Per començar, clona el repositori de GIT que es troba en aquesta ubicació i executa el codi Python per veure quin resultat dona.

https://github.com/pauitic/practica8_2

Exercici 2

- a. Executa les següents rutes XPath i observa el resultat que dona cada una. A continuació, explica les diferències que hi ha entre cada resultat i raona per què produeixen resultats diferents.

- i. node() vs text()

- **node()**:selecciona tots els nodes fills, incloent elements i nodes de text.
- **text()**:selecciona exclusivament els nodes de text.
-

Per tant, la diferència en els resultats es deu al fet que la primera ruta selecciona tots els nodes fills, mentre que la segona ruta selecciona únicament els nodes de text.

Ruta 1: `//div[@class='attribution']/p/node()`

Ruta 2: `//div[@class='attribution']/p/text()`

ii. Barra simple vs barra doble

Ruta 1: `//ul[@class='navbar-nav']/li/a/text()`

Ruta 2: `//ul[@class='navbar-nav']//li/a/text()`

- **La barra simple** / selecciona els fills directes d'un node.
- **La barra doble** // selecciona tots els descendents d'un node, independentment del seu nivell de profunditat.

b. Representa, en forma d'arbre l'estructura HTML que resulta d'avaluar la següent ruta XPath (pots ignorar els salts de línia i espais).

i. `(//div/h5) [6]`

Arbre

```
|  
|- div  
|   |- h5 (New Skateboard 3)
```

ii. `//div[@class='carousel-item'] [1]//h1`

Arbre

```
|  
|- div (classe: carousel-item, posició: 1)  
|   |- h1  
|       |- span  
|           |- span (Discounts)  
|           |- br  
|           |- span (20% Off)  
|       |- br  
|       |- span (id: all-products, On all our products!)
```

Exercici 3

Descobreix la ruta XPath per arribar a cada un dels elements que es demana tenint en compte només la informació que es proporciona a l'enunciat.

- c. Troba la ruta que arriba al **correu** de contacte que es troba al **<footer>** de la pàgina.

Comença la ruta a l'etiqueta <html>

`/html`

`/html/body/footer/div[@class='container']/div/div/div/div[@class='information-f']/p[3]/span`

sales@mail.com

- d. Troba la ruta que arriba a l'**atribut src** de la següent imatge (n'hi ha una al **<footer>**, i una al **<header>**, pots escollir):



images/logo.svg

`//header/a/img/@src`

- e. Troba la ruta fins a l'**atribut src** de les imatges amb **alt="Customer"**.

images/client-one.png

images/client-two.png

images/client-three.png

`//div[@class="carousel-inner"]/div[1]/img[@alt="Cliente"]/@src`

- f. Troba la ruta fins a l'**adreça** de la pàgina web **"Fake Street 123"**. Fes que l'adreça XPath parteixi la següent ubicació:

`//div[@class='information-f']/p[1]/strong/text()`

Fake Street 123

- g. Troba la ruta que arriba fins al **<h5>** del “**New Skateboard 12**”. **[Pista:** busca la utilitat de la funció *normalize-space()*].

```
<h5>                                <span>New Skateboard</span> 12
</h5>
```

```
//h5[normalize-space(text()) = "New Skateboard 12"]
```

- h. Partint de la ruta de l'apartat anterior, Troba la ruta que arriba fins al **preu** (text) del “**New Skateboard 12**”.

12

Exercici 4

Canvia la ruta a <https://scrapepark.org/table.html> . Amb l'ajuda del navegador, comprova què hi ha dins d'aquesta pàgina i troba la ruta XPath dels següents elements.

- i. Troba la ruta XPath a tots els **preus** dels **elements de color 'Blue'**. El resultat ha de ser el següent:

Blue
\$64
\$70
\$80
\$85

```
//tr[td[text()='Blue']]//td[@class="text-center"]
```

- j. Troba la ruta que imprimeix **els preus del longboard** que es troben a la 4a columna de la taula **pintats en vermell**.

Longboard
\$80
\$85
\$90
\$62
\$150

- k. Indica el nom i color de l'article que val \$110. Comença l'expressió de la següent manera: [pista]: hauràs de fer servir l'operador “[]”

```
//td[text()=' $110 ']
```

Skate

Special

```
//tr[td[contains(text(),'Purple')]]/td[not(contains(@style,'color:red'))]
```

- l. Troba la ruta a **tots els preus** dels objectes “Purple” **excepte el preu** que està pintat en vermell.

```
<td>Purple</td>
```

```
<td class="text-center">$55</td>
```

```
<td class="text-center">$60</td>
```

```
<td class="text-center">$72</td>
```

```
//tr[td[contains(text(),'Purple')]]/td[not(contains(@style,'color:red'))]
```